

Diseño y evaluación de la viabilidad de un agente virtual para la atención inicial en los consultorios jurídicos de la Facultad de Derecho de la Universidad de Costa Rica.

Luis Roberto Umaña Jiménez

PF-3311 Agentes Virtuales Inteligentes – Avance 2

a) Resumen de cambios desde el entregable 1

Desde la entrega anterior se han realizado ajustes importantes tanto en el diseño metodológico del estudio como en la arquitectura técnica del agente virtual, a partir de la retroalimentación recibida y del trabajo posterior. En primer lugar, se reformularon las preguntas de investigación para alinearlas mejor con el tipo de comparación que realmente se quiere observar en este piloto. En lugar de comparar el agente virtual frente al flujo tradicional basado en formularios, el estudio se centra ahora en comparar dos versiones del mismo agente: una con avatar y voz, y otra que funciona únicamente por texto. Esta decisión permite analizar de forma más precisa el aporte específico del *embodiment* y del canal de voz sobre la calidad percibida de las respuestas, la usabilidad y la experiencia de interacción en el contexto de los consultorios jurídicos.

En este proceso también se ajustó la matriz de consistencia metodológica y se incorporó una nueva pregunta de investigación orientada a medir el grado de concordancia entre las clasificaciones del agente y las de los abogados, utilizando el coeficiente de Cohen's Kappa. Con este cambio, el estudio deja de centrarse únicamente en la percepción subjetiva de calidad y experiencia, e incorpora además una medida más objetiva sobre cómo se alinea el comportamiento del agente con los criterios profesionales vigentes respecto a elegibilidad y tipo de caso. La matriz actual explícitamente vincula cada pregunta de investigación con su variable o constructo, los instrumentos que se utilizarán (rúbricas tipo Likert, SUS y matriz de clasificación) y las tareas que realizará cada participante durante la sesión de evaluación.

Por el lado técnico, se mantuvo el rol general del agente como asistente de atención inicial en los consultorios jurídicos, pero se revisó la arquitectura propuesta en el primer avance. En lugar de una integración basada en Unity, FlowiseAI y un modelo Qwen ejecutado localmente, se optó por una configuración más ligera y viable para el contexto del curso, utilizando Dify como servidor de orquestación del agente y un modelo de ChatGPT como núcleo de generación. Esta modificación responde a limitaciones de rendimiento observadas al probar modelos locales, y busca asegurar que el prototipo pueda ejecutarse de forma estable durante las sesiones de evaluación con los abogados.

Finalmente, se ajustó la forma en que se implementará el *embodiment* del agente. Aunque se mantiene la idea de ofrecer una versión con presencia visual y voz, en lugar de desarrollar un avatar desde cero en un motor como Unity se explora ahora la integración con un servicio de live avatar (HeyGen) conectado al backend de Dify. De esta manera, se conserva el enfoque

en comparar una versión con avatar y voz frente a otra solo texto, pero apoyándose en componentes más manejables para un piloto académico, sin renunciar a la posibilidad de evaluar el impacto que puede tener la presencia del avatar en la interacción inicial con las personas usuarias.

b) Estado actual del agente

En esta etapa del proyecto, el agente virtual se encuentra en una fase intermedia de implementación. Ya se ha avanzado en la configuración de la base técnica principal del sistema, pero todavía hay componentes que se encuentran en desarrollo y otros que dependen de la información que aún debe ser facilitada por los abogados de los consultorios.

Componentes ya implementados

Actualmente ya se cuenta con un servidor configurado con Dify, así como con un repositorio de conocimiento (*knowledge base*) conectado al sistema. Además, ya se encuentra configurado el modelo de lenguaje GPT-4o de OpenAI como núcleo del agente conversacional. Estos avances permiten trabajar sobre una base funcional real y no únicamente sobre un diseño conceptual, lo cual representa un cambio importante con respecto al entregable anterior, donde la arquitectura todavía se describía de manera más preliminar.

También se ha definido el flujo base de interacción que seguirá el agente durante la atención inicial. En este momento, las preguntas principales contempladas para la prueba son: nombre, edad, domicilio o lugar de residencia actual, y una descripción breve del caso. A partir de estas respuestas, el agente deberá intentar identificar la materia jurídica involucrada y orientar preliminarmente si el caso podría ser atendido o no por el consultorio, siempre con apoyo en la información recuperada desde el sistema RAG y sin sustituir el criterio profesional de los abogados.

Componentes en desarrollo

En este momento se están definiendo *prompts* de prueba para la demostración del agente, de manera que el prototipo pueda mostrar de forma comprensible el flujo general de atención inicial mientras se completa la alimentación definitiva del repositorio documental. Paralelamente, se está desarrollando un sitio web desde el cual el abogado evaluador pueda ingresar y elegir entre dos modalidades del sistema: una versión con avatar y voz, y otra versión solo texto tipo chat. Esta decisión se alinea directamente con el diseño metodológico actualizado, que plantea comparar ambas condiciones manteniendo constante la lógica del agente y variando únicamente la forma de interacción.

Además, una parte importante del trabajo actual se concentra en intentar concretar la integración del *live avatar* de HeyGen con el *backend* del agente en Dify. Aunque esta conexión todavía no puede considerarse terminada por completo, forma parte del objetivo técnico inmediato para esta entrega, ya que permitiría implementar la condición con avatar y voz prevista en el protocolo de evaluación.

Pendientes de insumos externos

Uno de los principales elementos todavía pendientes es la incorporación de información específica de los consultorios jurídicos que debe ser suministrada por los abogados. Entre esos insumos se encuentran las preguntas frecuentes, las zonas o ubicaciones donde sí se brinda atención y aquellas donde no, así como las materias legales que pueden o no ser atendidas por el consultorio. Esta información resulta esencial para alimentar adecuadamente el RAG y permitir que el agente responda y filtre casos de una manera más cercana a la realidad institucional del servicio.

Debido a que estos insumos aún no han sido entregados por completo, parte del desarrollo actual se está apoyando en *prompts* temporales de demostración. Sin embargo, se espera que esta información esté disponible próximamente, lo que permitirá ajustar el comportamiento del agente para que sus respuestas y clasificaciones se basen en lineamientos más precisos y reales de los consultorios.

c) Diseño metodológico del estudio

Este trabajo se plantea como un estudio piloto con evaluación de expertos, enfocado en valorar la viabilidad de un agente virtual para la atención inicial en los consultorios jurídicos de la Facultad de Derecho de la Universidad de Costa Rica. Este enfoque está apegado al alcance del curso y a la naturaleza del proyecto, ya que en esta etapa no se va a trabajar con usuarios reales, sino con abogados y abogadas con la experiencia requerida para valorar el comportamiento del agente desde su perspectiva profesional. De esta manera, se busca obtener información preliminar sobre la calidad del sistema, la experiencia de interacción y la consistencia del agente en relación con los criterios que se aplican en la valoración inicial de los consultorios.

A nivel de diseño, se compararán dos versiones del mismo agente virtual. La versión 1 (condición A) corresponde a un avatar visual e interacción por voz, la versión 2 (condición B) corresponde al mismo agente, con la misma lógica conversacional, las mismas reglas de elegibilidad y misma base de conocimiento, pero interactuando únicamente mediante texto. Esto permite observar mejor qué tanto influye la forma de interacción (con avatar y voz vs. solo texto) en la percepción de los abogados sobre el agente, y no que las diferencias observadas se deban a cambios en el contenido de las respuestas o en la lógica interna del agente.

La evaluación se llevará a cabo en torno a las tres preguntas de investigación planteadas. La primera se centra en la corrección, coherencia y utilidad de las respuestas del agente; la segunda, en la percepción de usabilidad y experiencia de interacción entre ambas modalidades; y la tercera, en el grado de concordancia entre las clasificaciones realizadas por el agente y las efectuadas por los abogados con respecto a elegibilidad y tipo de caso. Estas tres dimensiones permiten valorar el prototipo no solo desde la calidad percibida de sus respuestas, sino también desde la experiencia de uso y desde su apego al criterio profesional que se espera en el contexto de los consultorios jurídicos.

Elemento	Descripción
Tipo de estudio	Estudio piloto de carácter exploratorio con evaluación de expertos.
Propósito	Valorar la viabilidad del agente virtual en la atención inicial de consultorios jurídicos, tanto en la calidad de sus respuestas como en la experiencia de interacción y en su concordancia con el criterio profesional.
Participantes	Hasta un máximo de 3 abogados o abogadas vinculados a los consultorios jurídicos, con experiencia suficiente en la valoración inicial de casos y conocimiento del funcionamiento general del servicio.
Justificación de la muestra	Se trata de una evaluación experta de alcance piloto, donde interesa más la calidad del juicio profesional que un número amplio de participantes.
Criterios de inclusión	Tener experiencia suficiente en la valoración inicial de casos dentro del consultorio, conocer los criterios básicos de atención y aceptar participar voluntariamente en la sesión de evaluación.
Criterios de exclusión	No contar con experiencia suficiente para valorar criterios de elegibilidad, materias atendidas y orientación inicial del consultorio, o no poder completar la sesión de evaluación en ambas condiciones.
Plan de reclutamiento	El reclutamiento se realizó mediante contacto directo con 3 abogados(as) que podrían participar en el piloto, seleccionados por su experiencia y por considerarse personas con criterio adecuado para valorar el comportamiento del agente.

d) Métricas

Las métricas del estudio se definieron a partir de las preguntas de investigación y buscan evaluar tres dimensiones del prototipo: la calidad de las respuestas, la experiencia de interacción y la concordancia entre el agente y el criterio de los abogados. Con esto lo que se pretende es valorar no solo si el sistema responde bien, sino también si resulta útil y consistente dentro del contexto de los consultorios jurídicos.

Para la RQ1, se medirán tres aspectos de la calidad percibida de las respuestas: corrección, coherencia y utilidad. Esto permite observar si el agente responde de forma correcta, lógica y realmente útil para la valoración inicial del caso.

Para la RQ2, se evalúa la usabilidad percibida y la experiencia de interacción en las dos modalidades del sistema (con avatar y voz, y solo texto). Aquí se pretende ver cómo perciben

los abogados el uso de cada versión y si una de ellas ofrece una interacción más clara o más cómoda que la otra.

Para la RQ3, se pretende medir la concordancia entre las clasificaciones realizadas por el agente y las de los abogados respecto a elegibilidad y tipo de caso. Esta se analizará con el coeficiente de Cohen's Kappa, ya que nos permite estimar el nivel de coincidencia entre ambas clasificaciones.

Pregunta de investigación	Métrica	Qué se observa	Propósito
RQ1	Corrección	Si la respuesta del agente es adecuada para la orientación inicial del caso.	Valorar la calidad del contenido generado.
RQ1	Coherencia	Si la respuesta mantiene sentido interno y no presenta contradicciones.	Determinar si el agente responde de forma lógica y consistente.
RQ1	Utilidad	Si la respuesta ayuda realmente a avanzar en la atención inicial.	Estimar el valor práctico del agente dentro del flujo del consultorio.
RQ2	Usabilidad percibida	Qué tan clara, sencilla y manejable resulta cada modalidad del sistema.	Comparar la facilidad de uso entre la versión con avatar y voz y la versión solo texto.
RQ2	Experiencia de interacción	Cómo se percibe la interacción con el agente en cada condición.	Observar diferencias en comodidad, claridad y percepción general del uso del sistema.
RQ3	Concordancia agente-abogado	Nivel de coincidencia entre la clasificación del agente y la del abogado respecto a elegibilidad y tipo de caso.	Evaluar la alineación del agente con el criterio profesional.

e) Instrumentos de Recolección de Datos

Instrumento 1: Rúbrica tipo Likert para evaluar respuestas del agente (véase Anexo 1)

¿En qué literatura me baso para su aplicación? Se toma como base la literatura reciente sobre evaluación humana de agentes conversacionales y aplicaciones con modelos de lenguaje, donde se recomienda trabajar con juicio experto y escalas estructuradas para valorar aspectos como corrección, coherencia y utilidad de las respuestas, tal como proponen artículos de Abeysinghe y Circi (2024), Xu y Huang (2024), Kim et al. (2025) o de Gennaro y Rossi (2025).

¿Qué mide? Permite valorar qué tan correctas, coherentes y útiles resultan las respuestas del agente para una etapa de atención inicial.

¿Cómo se administra? El abogado revisa la respuesta del agente en cada caso y la califica en una escala de 1 a 5 en cada uno de los criterios definidos. También puede agregar un comentario breve si lo considera necesario.

¿En qué momento de la sesión se aplica? Se aplica después de revisar cada caso en la condición correspondiente.

Instrumento 2: Cuestionario SUS (véase Anexo 2)

¿En qué literatura me baso para su aplicación? Se utiliza la escala SUS porque es un instrumento ampliamente conocido y utilizado para evaluar la usabilidad de sistemas interactivos de forma rápida y sencilla, originalmente propuesto por Brooke (1996) y recomendado en múltiples estudios como una opción adecuada para distintos contextos y muestras pequeñas.

¿Qué mide? Permite conocer cómo percibe el participante la usabilidad de cada versión del agente.

¿Cómo se administra? Se aplica el formulario SUS completo después de que el participante interactúa con una versión del sistema. En este estudio se aplicará una vez para la versión con avatar y voz, y otra vez para la versión solo texto.

¿En qué momento de la sesión se aplica? Se aplica al finalizar la interacción con cada una de las dos modalidades del agente.

Instrumento 3: Formulario de clasificación de casos (véase Anexo 3)

¿En qué literatura me baso para su aplicación? Para estimar la concordancia entre la clasificación del agente y la de los abogados se utilizará el coeficiente de Cohen's Kappa (Cohen, 1960), que permite considerar el acuerdo más allá de lo esperable por azar.

¿Qué mide? Permite registrar si el abogado coincide o no con el agente en cuanto a elegibilidad del caso y tipo de asunto jurídico.

¿Cómo se administra? Para cada caso, el abogado completa un formulario breve indicando cómo clasificaría el caso según su propio criterio profesional. Luego esa información se compara con la salida del agente.

¿En qué momento de la sesión se aplica? Se completa después de revisar cada caso y observar la respuesta del agente.

Instrumento 4: Preguntas abiertas de cierre (véase Anexo 4)

¿En qué literatura me baso para su aplicación? Se apoya en el uso de preguntas abiertas como complemento de los instrumentos cuantitativos, con el fin de recoger observaciones, dudas o sugerencias que no siempre quedan reflejadas en una escala.

¿Qué mide? Permite recoger comentarios más abiertos sobre ventajas, limitaciones, riesgos y posibles mejoras del agente.

¿Cómo se administra? Al final de la sesión se le pide al participante que responda algunas preguntas abiertas de forma breve, según su experiencia durante la evaluación.

¿En qué momento de la sesión se aplica? Se aplica al cierre de la sesión, después de completar los demás instrumentos.

f) Protocolos de interacción

El protocolo de interacción define paso a paso cómo se llevará a cabo la sesión de evaluación con cada abogado participante, qué versión del agente se utilizará en cada momento y en qué orden se aplicarán los instrumentos de recolección de datos. El objetivo es que todas las personas participantes sigan una secuencia similar, de manera que las comparaciones entre condiciones sean claras y consistentes.

Flujo general de la sesión con cada abogado

Con cada participante se seguirá el siguiente orden:

1. Bienvenida y explicación breve del propósito del estudio, el rol del agente virtual y de la dinámica de la sesión.
2. Interacción con la condición A del agente (versión con avatar y voz) en los tres escenarios definidos.
3. Completar el formulario de evaluación de respuestas del agente (rúbrica tipo Likert) para las respuestas observadas en la condición A.
4. Completar el cuestionario SUS para valorar la usabilidad percibida de la condición A.

5. Interacción con la condición B del agente (versión solo texto tipo chat) en los mismos tres escenarios.
6. Completar nuevamente el formulario de evaluación de respuestas del agente para las respuestas observadas en la condición B.
7. Completar el cuestionario SUS para valorar la usabilidad percibida de la condición B.
8. Completar el formulario de clasificación de casos, indicando, para cada escenario y condición, la elegibilidad y el tipo de asunto según el criterio del abogado.
9. Responder el formulario de observaciones finales, con preguntas abiertas sobre ventajas, riesgos y posibles mejoras del agente.

De esta manera, primero se evalúa la versión con avatar y voz en todos los casos, luego la versión solo texto en los mismos escenarios y, al final, se recogen las percepciones más generales y las clasificaciones necesarias para analizar la concordancia entre el agente y los abogados.

Escenarios de interacción

Para la evaluación se utilizarán tres escenarios de casos simulados, que se presentarán al abogado tanto en la condición A como en la condición B del agente.

Escenario 1 – Caso de familia (pensión alimenticia)

Persona adulta que busca orientación sobre cómo iniciar o continuar un proceso de pensión alimenticia en favor de su hija menor de edad, frente a un padre que ha dejado de aportar a la manutención. El caso permite observar si el agente identifica la materia como familia, si considera el caso elegible para el consultorio y si ofrece una orientación inicial adecuada para esta etapa.

Escenario 2 – Caso laboral (despido y prestaciones)

Persona trabajadora despedida recientemente que duda si las prestaciones laborales ofrecidas por la empresa son correctas y quiere saber si el consultorio puede ayudarlo a revisar su situación. Este escenario permite evaluar si el agente identifica la materia como laboral, si lo considera potencialmente elegible y si orienta de forma clara sobre el tipo de asunto y los pasos iniciales a seguir.

Escenario 3 – Caso NO elegible (proceso penal en curso)

Persona con un proceso penal en curso, ya representada por un abogado particular, que consulta si los consultorios jurídicos pueden asumir su caso o cambiarle de defensor. Este escenario se utiliza para probar si el agente identifica la materia como penal, la clasifica como no elegible según los criterios del consultorio y explica de manera clara que este tipo de asuntos no forma parte del ámbito de atención del servicio, ofreciendo únicamente una orientación general.

Cada escenario se presenta de igual forma en ambas condiciones del agente, de manera que lo que cambia es el tipo de interacción (avatar y voz en la condición A, solo texto en la condición B), pero no el escenario ni los objetivos de la atención inicial.

Aplicación de los instrumentos dentro del protocolo

Al finalizar la interacción con los tres escenarios en la condición A, el abogado completa el formulario de evaluación de respuestas del agente, valorando corrección, coherencia y utilidad de las respuestas generadas en esa modalidad. Seguidamente, llena el cuestionario SUS correspondiente a la versión con avatar y voz, para dejar registrada su percepción de usabilidad de esta condición.

Después se repite el mismo procedimiento para la condición B, el abogado interactúa con los tres escenarios en la versión solo texto y, al finalizar, completa nuevamente el formulario de evaluación de respuestas y el cuestionario SUS, esta vez pensando exclusivamente en la modalidad de chat. De esta forma se pueden comparar las percepciones entre ambas versiones del agente.

Para finalizar la sesión, el abogado completa el formulario de clasificación de casos, indicando para cada escenario y condición cómo clasificaría la elegibilidad y la materia jurídica según su propio criterio profesional, y responde el formulario de observaciones finales, donde puede comentar ventajas, riesgos, limitaciones y aspectos de mejora. Los formularios completos que se utilizarán en cada etapa del protocolo se incluyen en los anexos del documento.

Anexos

Los formularios completos utilizados en la evaluación se encuentran en la carpeta “Anexos” asociada a este documento. A continuación, se indican sus nombres y contenido:

- **Anexo 1. Formulario de evaluación de respuestas del agente**
Rúbrica tipo Likert para valorar corrección, coherencia y utilidad de las respuestas del agente en cada caso y condición.
- **Anexo 2. Cuestionario SUS aplicado al agente virtual**
Formulario SUS utilizado para medir la usabilidad percibida de cada modalidad del agente.
- **Anexo 3. Formulario de clasificación para concordancia agente–abogado**
Instrumento para registrar la clasificación del abogado en cuanto a elegibilidad del caso y tipo de asunto jurídico y compararla con la clasificación del agente.
- **Anexo 4. Formulario de observaciones finales**
Preguntas abiertas de cierre para recoger comentarios, limitaciones percibidas y sugerencias de mejora.

Referencias

Hague Institute for Innovation of Law. (2021). Poverty and access to justice. HiiL.

Hague Institute for Innovation of Law. (2021). Use of digital technologies in judicial reform and access to justice. HiiL.

Stanford Legal Design Lab. (2023). AI & access to justice initiative: Research and pilots on responsible legal AI. Stanford University.

Bell, F., & McDonald, S. (2025). Interoperable legal AI for access to justice. *Yale Law Journal*, 134, 1–36.

International Legal Aid Group. (2025). AI in legal aid: Beyond the hype towards sustainable applications. ILAG.

Hague Institute for Innovation of Law. (2025). AI and access to justice: A snapshot of current trends and future potential. HiiL.

New York State Bar Association. (2026). Report and recommendations on artificial intelligence and access to justice in 2025. NYSBA.

Amato, G., Fonisto, A., & Vadicamo, L. (2023). An intelligent conversational agent for the legal domain. *Artificial Intelligence and Law*.

Sharma, M., Russell-Rose, T., Barakat, L., & Matsuo, A. (2021). Building a legal dialogue system: Development process, challenges and opportunities. En Proceedings of the 19th International Conference on Artificial Intelligence and Law (ICAIL 2021) (pp. 1–10). ACM.

Shah, D., & Srivastava, S. (2022). Conversational AI for legal reasoning and contract automation. *International Journal of Innovative Science and Research Technology*, 7(6), 847–855.

Magni, M., & Milella, F. (2025). Conversational agents in the legal domain: A systematic review of the literature. En K. Arai (Ed.), *Advances in information and communication: Proceedings of the 2025 Future of Information and Communication Conference (FICC)* (Vol. 3, pp. 183–204). Springer.

Ivanova, M., & Petrova, L. (2025). The emergence of AI-based chatbots in legal services. *Journal of Intelligent Law and Computing*, 2(4), 55–78.

Asparuhov, V. (2024). Empowering justice: Blockchain and legal chatbots as catalysts for access to legal aid. *International Journal of Law, Education and Technology*, 4(4), 106–150.

Vassilopoulos, A. (2022). Can AI chatbots improve access to legal information? A case study (Master's thesis). HEC Montréal.

König, L., & Schneider, J. (2021). Conversational agents as trustworthy autonomous systems (Trust-CA). *Dagstuhl Reports*, 11(8), 76–102.

Abeyasinghe, B., & Circi, R. (2024). The challenges of evaluating LLM applications: An analysis of automated, human, and LLM-based approaches. *arXiv*.

Xu, H., & Huang, T. (2024). Human evaluation of large language model chatbots: Dimensions, metrics, and challenges. *ACM Computing Surveys*, 57(4), 1–35.

Kim, J., Park, S., & Choi, K. (2025). Evaluation of the readability, quality, and accuracy of AI chatbot responses across platforms. *Journal of Medical Internet Research*, 27, e126362.

de Gennaro, G., & Rossi, F. (2025). Evaluating the quality of psychotherapy conversational agents: The CAPE framework. *JMIR Formative Research*, 9, e65605.

Müller, M., Zhang, Y., & Das, R. (2023). Efficient evaluation of dialogue agents: Self-play and bot–bot methods. *Artificial Intelligence and Social Computing*, 72, 77–88.

Li, Y., Wang, X., & Chen, J. (2024). Understanding virtual agents' service quality in the context of customer service: A fit–viability perspective. *Electronic Commerce Research and Applications*, 62, 101293.

Osorio, A. E., & Santos, R. (2024). Virtual agents in the public service: Examining citizens' value-in-use. *Public Management Review*, 26(1), 73–88.

West, S. M. (2022). The virtual public servant: Robots and virtual agents in frontline public service. En *Handbook of Digital Public Service* (pp. 187–210). Routledge.

Norton, T. (2024). Towards responsible AI in legal services: The case of legal chatbots. *Regulation & Governance*, 18(2), 231–249.

Cohen, J. (1960). A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, 20(1), 37–46.